Uniwersytet Warszawski
Wydział Matematyki, Informatyki i Mechaniki

Katarzyna Wręczycka
Nr albumu: 292555

Implementacja metody wyszukiwania potencjalnych obszarów regulatorowych

Praca licencjacka
na kierunku BIOINFORMATYKA I BIOLOGIA SYSTEMÓW

Praca wykonana pod kierunkiem
dr Bartosza Wilczyńskiego
Instytut Informatyki

Wrzesień 2012

Oświadczenie kierującego pracą

Potwierdzam, że niniejsza praca została przygotowana pod moim kierunkiem i kwalifikuje się do przedstawienia jej w postępowaniu o nadanie tytułu zawodowego.

Data Podpis kierującego pracą

Oświadczenie autora (autorów) pracy

Świadom odpowiedzialności prawnej oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami.

Oświadczam również, że przedstawiona praca nie była wcześniej przedmiotem procedur związanych z uzyskaniem tytułu zawodowego w wyższej uczelni.

Oświadczam ponadto, że niniejsza wersja pracy jest identyczna z załączoną wersją elektroniczną.

Data Podpis autora (autorów) pracy

Streszczenie

W pracy opisano metodologię oraz implementację oprogramowania do automatycznej analizy miejsc wiązania czynników transkrypcyjnych pod kątem występowania w nich nadreprezentowanych motywów wygenerowanych de novo oraz wybranych z bazy danych Jaspar. Jako przykład zastosowania oprogramowania wskazano grupę genów kodujących miozynę u człowieka, jak i w genomach myszy i szczura przy długości konserwowanych bloków sekwencji 10 kb i dozwolonym procencie identyczności sekwencji 70%.

Słowa kluczowe

motyw DNA, sekwencje regulatorowe, ortolog, sekwencje zachowane ewolucyjnie

Dziedzina pracy (kody wg programu Socrates-Erasmus)

11.9 Inne dziedziny nauki związane z Matematyką i Informatyką

Klasyfikacja tematyczna

J. Computer Applications
J.3 LIFE AND MEDICAL SCIENCES Subjects: Biology and genetics

Tytuł pracy w języku angielskim

Potential regulatory region discovery method implementation

Spis treści

1. Wstęp . . . 5
1.1. Rola i budowa DNA . . . 5
1.2. Mechanizm regulacji transkrypcji u eukariontów . . . 6
1.2.1. Tworzenie kompleksu preincjacyjnego z użyciem polimerazy RNA II . 7
1.2.2. Tworzenie kompleksu incjacyjnego z użyciem polimerazy RNA II . . . 8
1.3. Motyw DNA . . . 9
1.3.1. Metody reprezentacji motywów . . . 10
1.3.2. Metody znajdowania motywów . . . 12
1.4. Ewolucyjnie zachowane moduły sekwencji nukleotydowych . . . 13
1.5. Sekwencje ortologiczne oraz paralogiczne . . . 15

2. Metody . . . 17
2.1. Baza danych sekwencji nukleotydowych Ensembl . . . 17
2.2. Konserwowane segmenty MSA . . . 17
2.3. Statystyczna analiza motywów DNA . . . 19
2.4. Opis implementacji . . . 19

3. Przykład zastosowania . . . 23

4. Podsumowanie . . . 27

A. Nadreprezentowane motywy . . . 29

Bibliografia . . . 29

Rozdział 1

Wstęp

1.1. Rola i budowa DNA

Kwas deoksyrybonukleinowy, w skrócie DNA (ang. DeoxyriboNucleic Acid) to podstawowa cząsteczka występująca u wszystkich organizmów żywych na Ziemi. DNA jest liniowym, nierozgałęzionym polimerem, składającym się z nukleotydów, z których każdy jest zbudowany z pięciowęglowego cukru deoksyrybozy, reszty kwasu fosforowego oraz zasady azotowej. Strukturę łańcucha DNA przedstawiono na rysunku 1.1.

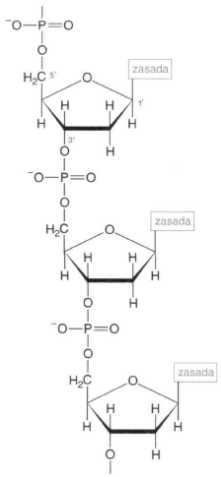

Rysunek 1.1: Rysunek przedstawia fragment budowy kwasu deoksyrybonukleinowego. Cyfra ze znakiem prim (') wskazuje numer atomu w cząsteczce cukru. Zasadzie odpowiada jedna z zasad azotowych: adenina, tymina, cytozyna lub guanina.

Reszty fosforanowe i cukrowe pełnią rolę strukturalną, podczas gdy zmienną część DNA stanowią zasady azotowe: purynowe - adenina (A) i guanina (G) oraz pirymidynowe - tymina (T) i cytozyna (C) widoczne na rysunku 1.2.

Nukleotydy tworzą liniowy łańcuch DNA poprzez łączenie się za pomocą wiązań fosfodiestrowych, co pozwala rozważać DNA jako ciąg liter nad alfabetem {A,C,G,T}. Ściśle określona sekwencja zasad nukleinowych w DNA niesie informację genetyczną.

Głównym zadaniem DNA jest przechowywanie i przenoszenie informacji genetycznej pomiędzy pokoleniami. Pełni więc rolę nośnika informacji genetycznej u organizmów żywych. Z DNA zbudowane są wszystkie geny komórek i niektórych wirusów.

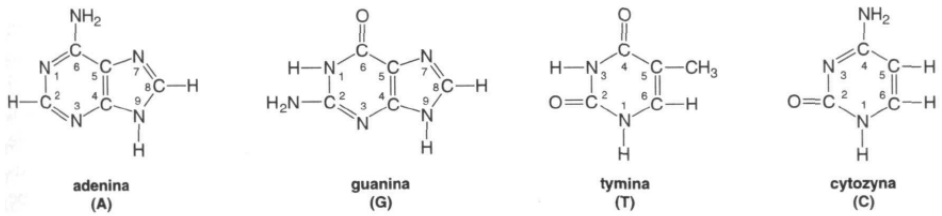

Rysunek 1.2: Rodzaje zasad azotowych w DNA.

Odkrycie Jamesa Watsona i Francisa Cricka w 1953 roku ujawniło przestrzenną strukturę DNA. Stworzono model dwuniciowej helisy DNA oraz odkryto regułę komplementarności widoczne na rysunku **??**. W przypadku DNA oznacza to, że adenina łączy się poprzez dwa wiązania wodorowe z tyminą, a guaniną z cytozyną poprzez trzy wiązania wodorowe. W regionach gdzie łączą się ze sobą zasady komplementarne tworzą się fragmenty dwuniciowe. DNA występuje więc w postaci dwóch połączonych antyrównoległych nici.

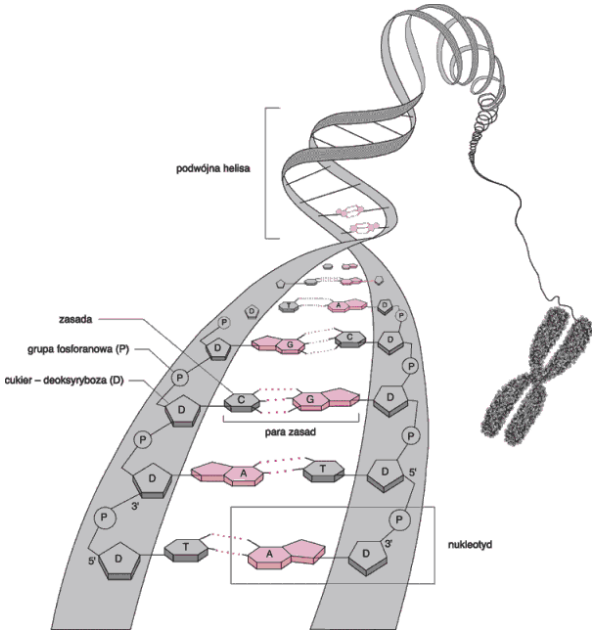

Rysunek 1.3: Rysunek przedstawiający zasadę komplementarności zasad i tworzenie sie podwójnej helikalnej stuktury DNA. Przyjęto oznaczenia: D-deoksyryboza, P-reszta kwasu fosforowego, A-adenina, T-Tymina, G-Guanina, C-Cytozyna [6].

Oprócz DNA w komórkach organizmów występuje także kwas rybonukleinowy, czyli RNA (ang. RiboNucleic Acid). Oba kwasy zbudowane są analogocznie, jednak różnią się funkcjami i właściwościami strukturalnymi. Głownymi różnicami w budowie łańcucha jest to, że w RNA zamiast deoksyrybozy występuje ryboza oraz zamiast tyminy (T) uracyl (U). RNA jest dynamiczną, mniej stabilną cząsteczką niż DNA.

1.2. Mechanizm regulacji transkrypcji u eukariontów

W każdej komórce organizmu, aby mogła ona wykorzystać informację biologiczną zakodowaną w swoim genomie, zachodzi skoordynowana ekspresja poszczególnych genów. Każdy z nich

jest jednostką informacji mogącą wpływać na fenotyp organizmu. Według centralnego dogmatu biologii informacja genetyczna generalnie przepływa jednokierunkowo od DNA przez RNA do białek będących składnikami budulcowymi komórek i składowymi praktycznie wszystkich procesów komórkowych [13]. Mimo iż wykazano, że to nie jedyna droga przekazywania informacji genetycznej, nadal uważana jest za główną.

Przepisywanie informacji z DNA na RNA nazywane jest transkrypcją. Pierwszym krokiem, który umożliwia ten proces jest odseparowanie od siebie fragmentów dwóch nici DNA. Wtedy możliwe jest przyłączenie białka polimerazy RNA zależnej od DNA (w skrócie polimerazy RNA) do miejsca startu transkrypcji (TSS, ang. Transcription Start Site) i produkowanie przez nią na matrycy DNA (nić 3'-5' DNA) komplementarnej do niej nici mRNA (ang. messenger RNA). Ekspresja wielu genów, czyli procesy odczytania informacji genetycznej w genach i przepisanie jej na produkty (białka lub różne formy RNA), jest unikalna. Przykład stanowi ekspresja genów zarodków transgenicznych myszy zależna od momentu życia [30]. Po utworzeniu prawidłowego kompleksu polimeraza RNA przemieszcza się wzdłuz matrycy dokładając kolejne nukleotydy do nowo powstałej nici mRNA (faza elongacji) i kończy tranksrypcję rozpadem kompleksu DNA i polimerazy RNA oraz uwolnieniem nowo powstałej cząsteczki RNA (faza terminacji).

Geny kodujące białka u eukariontów są w większości nieaktywne, dopóki nie zostaną aktywowane przez związanie czynników transkrypcyjnych (aktywatorów) do licznych miejsc regulatorowych DNA. Aktywatory współdziałają ze sobą umożliwiając stworzenie i złożenie efektywnego kompleksu białkowego w miejscu inicjującym transkrypcję.

1.2.1. Tworzenie kompleksu preincjacyjnego z użyciem polimerazy RNA II

Rozpoznanie promotora i inicjacja trankrypcji przez polimeraze RNA II wymaga obecności czynników transkrypcyjnych (TF). Posiadają one zdolność wiązania się do regionów nici DNA, zwanych regionami regulatorowymi. Dzieli się je na ogólne oraz specyficzne. Ogólne TF obecne są przy każdej inicjacji transkrypcji. Tworzą one platformę, do której wiąże się polimeraza RNA. Specyficzne TF przyłączają się do kompleksu inicjującego transkrypcje genów, których ekspresja zachodzi w specyficznych warunkach, między innymi związanych z sygnałami zewnętrznymi [19]. Ogólne czynniki trankrypcyjne dla polimerazy RNA II (TFII) wiążą się do regionu promotorowego, natomiast TF specyficzne mogą się wiązać do promotora i/lub sekwencji wzmacniających opisanych w rozdziale 1.2.2 [12].

W promotorze podstawowym (ang. core promotor) rozpoznawanym przez polimerazę RNA II występuje sekwencja inicjatorowa (Inr) oraz kaseta TATA. Istnieją jednak geny, w których znajduje tylko jeden z tych elementów lub nawet żaden. Geny nie posiadające sekwencji promotora podstawowego nazywane są genami zerowymi, a ich transkrypcja zachodzi w sposób ciągły [10]. W niektórych genach występują także dodatkowe elementy promotora podstawowego. Należą do nich BRE (ang. TFIIB Recognition Element), DPE (ang. Downstream Promoter Element) oraz inne sekwencje położne najczęściej powyżej miejsca startu transkrypcji [25]. Ogólny schemat promotora pokazany jest na rysunku 1.4.

Kaseta TATA jest rozpoznawana przez czynnik transkrypcyjny TBP (ang. TATA Binding Protein), który jest koniecznym elementem umożliwiającym polimerazie RNA II wiązanie do DNA. Jest on składnikiem czynnika transkrypcyjnego TFIID. Czynniki trankrypcyjne TFIIA oraz TFIIB również są niezbędne polimerazie RNA II. Wiążą się do kompleksu inicjacyjnego tuż po TFIID. Gdy polimeraza zbliża się do kompleksu przyłącza się do niej TFIIF. Zanim polimeraza będzie mogła przesuwac się po matrycy i zacząć elongację nowo powstałej cząsteczki RNA, musi ona opuścic sekwencję promotorową. W tym procesie niezbędne są trzy kompleksy TF: TFIIE, TFIIH oraz TFIIJ. Proces tworzenia kompleksu preincjacyjnego

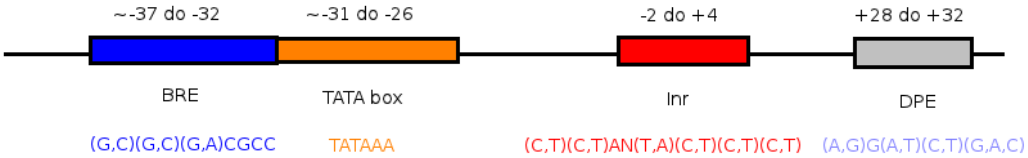

Rysunek 1.4: Ogólny model miejsc promotorowych eukariontów. Pierwszy transkrybowany nukleotyd posiada numer +1. Pod każdym elementem promotora podstawowego narysowany jest jego wzorzec sekwencji nukleotydowej [11]. W nawiasach okrągłych zaznaczono możliwe nukleotydy na danej pozycji. Przyjęto oznaczenia: A-adenina, T-tymina, C-cytozyna, G-guanina, N-dowolny nukleotyd.

widoczny jest na rysunku 1.5.

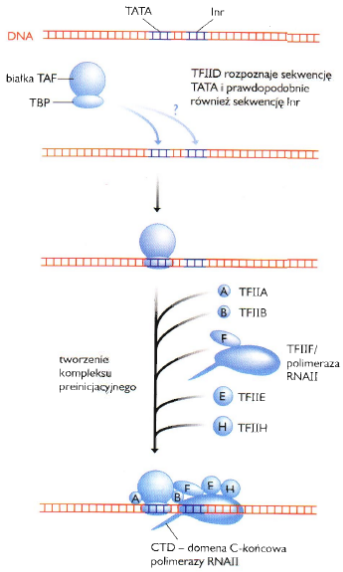

Rysunek 1.5: Składanie kompleksu preinicjacyjnego polimerazy RNA II [10].

1.2.2. Tworzenie kompleksu incjacyjnego z użyciem polimerazy RNA II

Specyficzne czynniki transkrypcyjne, nazywane czynnikami transkrypcyjnymi, są selektywnie aktywowane dla pewnych grup genów i angażowane w regulację ekspresji genów w odpowiedzi na panujące warunki wewnątrz oraz na zewnątrz komórki. Ich wiązanie pomaga w tworzeniu aparatu transkrypcyjnego oraz zwiększa częstość inicjacji transkrypcji [12].

Nie przyłączają się one bezpośrednio do polimerazy RNA II. Kontaktują się z aparatem preincjacyjnym zazwyczaj przez TFIID, rzadziej przez TFIIB lub TFIIA. Wiążą się one do DNA w miejscach sekwencji regulatorowych, m.in sekwencji wzmacniających (ang. enhancer) oraz sekwencji wyciszające (ang. silencer). Wiele sekwencji regulatorowych nie jest jeszcze znanych. Sekwencje wzmacniające oraz wyciszające położone są często w znacznej odległości od sekwencji kodującej. Jest to możliwe dzięki właściwości DNA, która powoduje, że może ona tworzyć pętle. Dzięki temu białka aktywujące (ang. activators) lub represorowe (ang. repressors) mogą związać się do wzmacniaczy lub analogicznie wyciszaczy oraz przyłączyć się

do kompleksu inicjującego tranksypcję za pośrednictwem białek nazywanych mediatorami.

Uważa się, że w organizmach eukariontycznych podstawowy mechanizm działania represorów opiera się na zasadzie inaktywacji aktywatorów. Mechanizm tworzenia pętli pozwala jednemu wzmacniaczowi lub represorowi brać udział w procesie regulacji ekspresji wielu genów w określonym rejonie. W celu izolacji przestrzennej ich rejonów aktywności chromosomy podzielone są na regulatorowe sąsiedztwa rozdzielone przez sekwencje znane jako izolatory chromosomowe (ang. insulators) [12].

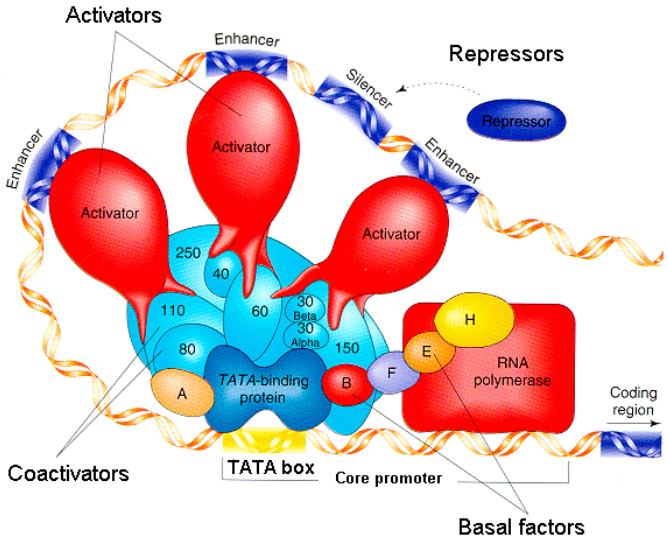

Rysunek 1.6: Rysunek przedstawiający kompleks inicjacyjny polimerazy RNA II. Przyjęto oznaczenia: Activators-aktywatory, Repressors-represory, Coactivators-koaktywatory, Basal factors-podstawowe czynniki transkrypcyjne, RNA polymerase-polimeraza RNA II, TATA box-kaseta TATA ,Enhancer-sekwencja wzmacniająca, Silencer-sekwencja wyciszająca, A-TFIIA, B-TFIIB, F-TFIIF, E-TFIIE, H-TFIIH [20].

Organizmy eukariontyczne stosują różne, skomplikowane strategie regulujące transkrypcję. Przedstawiono jedynie ich ogólny schemat.

1.3. Motyw DNA

Motyw (ang. sequence motif) to krótki (około 10-15 par zasad) powtarzający sie wzorzec sekwencji nukleotydowej lub aminokwasowej [26]. Motywy DNA są miejscami wiązania czynników transkrypcyjnych oraz cząsteczek RNA [15].

Dawniej motywy odkrywane były jedynie za pomocą metod doświadczalnych m.in DNA footprinting [10] czy ChiP-chip [14]. Dziś, oprócz tradycyjnych metod, metody obliczeniowe pozwalają generować ogromną ilość informacji na temat potencjalnych sekwencji regulatorowych, w tym motywów, przez przeszukiwanie sekwencji DNA pod względem nadreprezentowanych wzorców DNA w regionach związanych ze sobą genów (na przykład genów z podobnym wzorcem ekspresji lub podobną funkcją ich produktów) [15]. Używając opogramowania komputerowego możemy znaleźć tysiące motywów w zadanej sekwencji bez znajomości czynników transkrypcyjnych, które się do nich wiąża.

1.3.1. Metody reprezentacji motywów

Motywem nazywa się model reprezentujący silnie konserwowane oraz funkcjonalne segmenty identyfikowane w przyrównaniach wielu sekwencji. Istnieje wiele sposobów reprezentacji motywów, m.in: konsensus, macierz PSSM oraz graficzne logo pokazane na rysunku 1.7. Powyższe definicje zostaną uściślone w następnych akapitach.

Instancjami motywu nazywa się fragmenty sekwencji dobrze pasujące do motywu.

pozycja	1	2	3	4	5	6
sekwencja 1	A	T	G	T	C	G
sekwencja 2	A	A	G	A	C	A
sekwencja 3	A	A	C	T	C	A
sekwencja 4	A	G	G	A	G	G
sekwencja 5	A	C	C	T	C	G

(a)

	A	A	C	T	C	G

(b)

A	1	0.4	-	0.4	-	0.4
C	-	0.2	-	0.6	-	-
G	-	0.2	0.6	-	0.2	0.6
T	-	0.2	0.4	-	0.8	-

(c)

A	1.7	0.3	-	0.4	-	0.4
C	-	0	-	1.6	-	-
G	-	-0.5	1.1	-	-0.5	1.1
T	-	-0.2	1.4	-	1.8	-

(d)

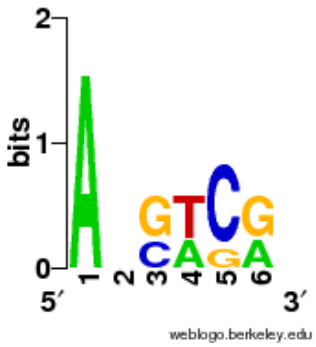

(e)

Rysunek 1.7: Przykład miejsca wiązania czynnika transkrypcyjnego. (a) Pięc instancji motywu będących miejscami wiązania TF. (b) Konsensus motywu. (c) Tabela częstości występowania nukleotydów na poszczególnych pozycjach motywu. (d) Macierz PSSM motywu (dla rozkładu tła (b_A,b_T,b_G,b_C = (0.3,0.2,0.27,0.23)). (e) Logo sekwencyjne.

Konsensus

Konsensus (ang. consensus sequence) jest obliczany na podstawie najczęściej występujących zasad nukleinowych na każdej pozycji w przyrównanych sekwencjach [15]. Konsensusem sekwencji $s_1, \ldots, s_n$ długości d nazwiemy sekwencję c, zdefiniowaną jako:

$$c_k = \arg \max_{i \in \{A,C,G,T\}} |\{j \ : \ s_{j,k} = i\}|,$$

dla $k \in 1, \ldots, d$, $j \in 1, \ldots, n$. Przykład konsensusu pokazano na rysunku 1.7 b.

Macierz PSSM

Macierz PSSM (ang. Position-Specific Scoring Matrix) to tabela zawierająca informacje o prawdopodobieństwie występowania nukleotydów w każdej pozycji przyrównania wielu sekwencji. Wartości w macierzy odpowiadają logarytmom ilorazu szans poszczególnych reszt pod warunkiem, że dana reszta pochodzi z rozkładu opisanego przez macierz motywu lub rozkładu tła [33]. Zakłada się, że w modelu tła, czyli w model biorącym pod uwagę częstość występowania nukleotydów w całym badanym obszarze, nukleotydy generowane są niezależnie. Oznaczmy przez b_i prawdopodobieństwo wygenerowania nukleotydu i z rozkładu tła dla $i \in \{A, G, C, T\}$, natomiast prawdopodobieńswtwo wygenerowania nukleotydu i na pozycji k motywu przez $p_{i,k}$ dla $i \in \{A, G, C, T\}$, $k \in \{1, \ldots, d\}$, gdzie d jest długością motywu. Wtedy w macierzy PSSM w wierszu i w kolumnie k stoi wartość:

$$m_{i,k} = log_2 \frac{p_{i,k}}{b_i}.$$

Przykładowa macierz PSSM znajduje się na rysunku 1.7d.

PSSM może posłużyć do oceny czy dany fragment sekwencji jest instancją motywu (to znaczy pochodzi z rozkładu $(p_{i,k})_{i \in \{A,G,C,T\}, k \in \{1,\ldots,d\}}$) czy pochodzi z rozkładu tła (produktu rozkładów $(b_i)_{i \in \{A,G,C,T\}}$). Dla fragmentu sekwencji $t_1 \cdots t_d$ (dlugości d) suma:

$$\sum_{k=1}^{d} m_{t_k,k} \tag{1}$$

określa logarytm ilorazu prawdopodobieństw przy założeniu, że fragment t jest instancją motywu lub pochodzi z rozkładu tła.

Logo sekwencyjne

Przyrównanie wielu sekwencji często przedstawia się w postaci graficznej zwanej logo. Każda pozycja logo składa się z liter ułożonych jedna na drugiej odpowiadających resztom danej kolumny przyrównania wielu sekwencji. Wysokość kolumny określa stopień konserwowania danej pozycji, a wysokość poszczególnych liter odzwierciedla względną częstość poszczególnych reszt [32]. Obliczana jest według wzoru:

$$I_i = \sum_{k=1}^{d} \hat{p}_{i,k} \ log_2 \frac{\hat{p}_{i,k}}{\frac{1}{4}} = 2 + \sum_{k=1}^{d} \hat{p}_{i,k} \ log_2 \ \hat{p}_{i,k}$$

gdzie $\hat{p}_{b,i}$ to częstość występowania zasady i na pozycji k w sekwencji [15].

Często bierze się również pod uwagę znany rozkład nukleotydów w genomie. Dla organizmów takich jak *E.coli*, gdzie 51% genomu pokrywają zasady GC lub u człowieka 41% taka

informacja jest bardzo przydatna. Istnieje wiele innych organizmów, które posiadają skrajną zawartość par GC w genomie, na przykład *Plasmodium falciparum*(19%) czy *Streptomyces coelicolor*(72%). Reprezentacja motywu uwzględniająca model tła obliczana jest według wzoru będąca uogólnieniem poprzedniego:

$$I_i = \sum_{k=1}^{d} \hat{p}_{i,k} log_2 \frac{\hat{p}_{i,k}}{\hat{b}_i}$$

gdzie $\hat{b}_i$ to częstość nukleotydu i w genomie [15]. Przykład loga sekwencyjnego uwzględniające tą poprawkę widoczne jest na rysunku 1.7 e.

1.3.2. Metody znajdowania motywów

Wyszukiwanie znanych motywów

Miejsca wiązania czynników transkrypcyjnych, które zostały wykryte metodami doświadczalnymi przechowywane są w wielu bazach danych dostępnych online. Przykładami są baza TRANSFAC (http://www.gene-regulation.com/pub/databases.html/) oraz JASPAR [31] zawierające informacje o motywach w genomach eukariontów,
YEASTRACT (http://www.yeastract.com/) u drożdzy, SCPD (http://rulai.cshl.edu/SCPD/) u S.cerevisiae, RegulonDB (http://regulondb.ccg.unam.mx/) u E.coli oraz
PRODORIC (http://www.prodoric.de/) u prokariontów [15].

Wyszukiwanie motywów *de novo*

W celu wyszukania nowych potencjalnych motywów za pomocą metod obliczeniowych wyróżnia się trzy podejścia: zliczeniowe, deterministyczne oraz probabilistyczne [14].

Pierwsze z nich proponuje prosty algorytm, w którym dla każdego możliwego motywu oblicza się liczbę jego wystąpień w sekwencji oraz wybiera się tylko te motywy, które są najliczniej reprezentowane. Przykładami modyfikacji tej metody jest dopuszczenie dodatkowych znaków (nomenklatura IUPAC [22]) lub dopuszczenie przerw w instancjach motywu. Taki model jest mało przydatny w praktycznych zastosowaniach. Usprawnia się go w połączeniu z innymi metodami. Metody wyliczeniowe używają do przeszukiwania motywów całego obszaru danej sekwencji, dlatego nie ma zagrożenia, że utkną w lokalnym ekstremum. Z drugiej strony ich wadą jest to, że mogą pomijać subtelne wzorce obecne w prawdziwych miejscach wiązania czynników transkrypcyjnych.

Metody deterministyczne wykorzystują algorytm EM (ang. Expectation Maximization). Składa się on z dwóch kroków wykonywanych na przemian tak długo, aż pomiędzy kolejnymi przebiegami nie dochodzi do zauważalnej poprawy. Zakładając, że mamy dany PSSM motywu możemy ocenić każdą konfigurację położeń jego instancji w sekwencjach. W każdej konfiguracji położeń możemy wyestymować nową macierz PSSM (poprzez zliczenie liter w poszczególnych pozycjach, uwzględniając rozkład tła). Biorąc średnią nowych macierzy PSSM odpowiednio ważonych ocenami dostaniemy macierz PSSM, którą użyjemy w kolejnej iteracji algorytmu. Wadą algorytmu jest to, że wynik końcowy zależy od początkowego wylosowania pozycji instancji motywu oraz obliczenia mogą utknąc w lokalnym ekstremum. Jedną z popularnych implementacji algorymtu EM jest MEME (ang. Multiple EM For Motif Elicitation) [7].

Kolejna metoda jest bardzo podobna do poprzedniej i jednocześnie wykorzystuje podejście stochastyczne. Algorytm próbkowania Gibbsa, podobnie jak w algorytmie EM losuje początkowe pozycje instacji motywu. Dla podanych n sekwencji w przyrówaniu oraz znanej

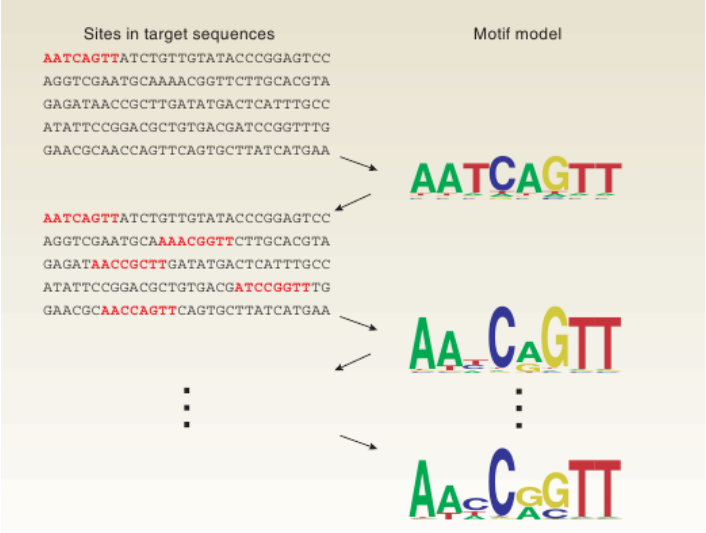

Rysunek 1.8: Rysunek przedstawia schemat działania algorytmu EM w programie MEME [7].

długości motywu może zostać wyznaczony rozkład warunkowy pozycji instancji motywu w i-tej sekwencji:

$$I_i \mid \{I_1, \ldots, I_n\} \setminus \{I_i\}.$$

Algorytm polega na iteracyjnym wybieraniu rozkładu warunkowego I_i zdefiniowanego powyżej oraz zmiany pozycji instancji motywu w i-tej sekwencji przez losowanie jej z wcześniej obliczonego rozkładu. Często interpretuje się próbnik Gibbsa jako szczególną wersje algorytmu Metropolisa–Hastingsa, gdzie w kolejnych krokach algorytmu zmienne I_i losowane są z podanego rozkładu oraz każdy krok próbkowania jest akceptowany (ma prawdopodobieństwo zaakceptowania równe 1). AlignACE (ang. Aligns Nucleic Acid Conserved Elements) jest przykładem programu wykorzystującym opisany algorytm [21].

1.4. Ewolucyjnie zachowane moduły sekwencji nukleotydowych

Ewolucyjnie zachowane sekwencje, nazywane również konserwowanymi sekwencjami to takie, które podczas ewolucji nie zmieniają się wcale lub tylko w niewielkim stopniu. U wielu gatunków oddalonych od siebie pod względem ewolucyjnym są więc podobne lub nawet identyczne.

Konserwowane sekwencje nukleotydowe w wielu genomach stały się źródłem badań nad sprawdzeniem ich funkcjonalności, w szczególności tych należących do człowieka.

Wśród genomów człowieka, myszy i szczura istnieje 481 fragmentów sekwencji dłuższych niż 200 par zasad, które są całkowicie zachowane ewolucyjnie, to znaczy posiadają identyczność sekwencyjną na poziomie 100% [9]. Niemal wszystkie z tych fragmentów są silnie konserwowane również w genomach kurczaka i psa z identycznością sekwencyjną odpowiednio 95% i 99%. Wiele z nich zachowane są także w genomie ryb. Oznacza to, że pewne fragmenty genomów zostały zachowane ewolucyjnie od ponad 300 milionów lat i sugeruje, że mają one rolę niezbędną organizmom do prawidłowego rozwóju oraz przeżycia.

Fragmenty te znane są one pod wieloma nazwami: ultraconserved elements (UCEs), conserved nongenic sequences (CNSs), multiple conserved sequences (MCSs), ultraconserved regions (UCRs) oraz highly conserved regions (HCRs) [8].

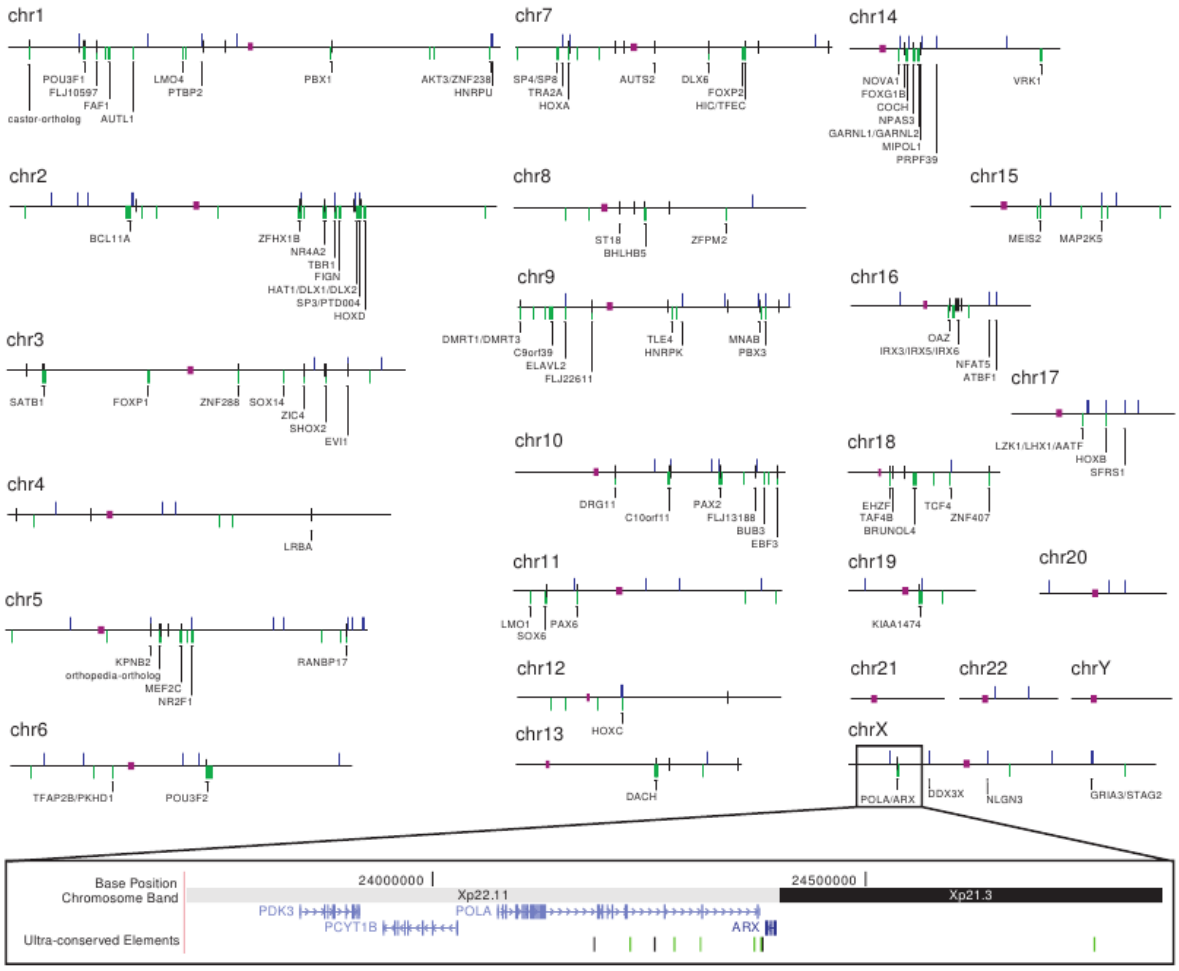

Rysunek 1.9: Rysunek przedstawia lokalizację 481 ultrakonserwowanych sekwencji (UCEs) w 24 ludzkich chromosomach. UCEs leżące częściowo w sekwencjach kodujących genów (egzonach) zostały zaznaczone przez niebieska pionową kreskę nad chromosomami, niekodujące UCEs przez zieloną kreskę poniżej chromosomu i te w których, jeszcze nie roztrzygnięto czy są kodujące przez czarna kreskę na linii reprezentującej chromosom. Nadano nazwy tym fragmentom DNA (klastrom), które składaja się połączonych ze sobą UCEs odseparowanych od siebie o mniej niż 675 kb nukleotydów. Jeden z klastrów został powiększony (poniżej) znajdujący się w pobliżu genu ARX. [9].

Jak wiadomo tylko około 1-2% genomu człowieka koduje białka, pomimo tego większość ludzkiego DNA ulega transkrypcji. Pojawia się coraz więcej przesłanek, że silnie konserwowane sekwencje, które nie kodują białek również mogą posiadać istotną rolę niezbędną do funkcjonowania organizmów żywych.

Ze wszystkich 481 UCE 53% nie wykazuje dowodów transkrypcji (ang. non-exonic UCEs), 23% obejmuje sekwencje kodujące (ang. exonic UCEs), a 24% to sekwencje, w których nie roztrzygnięto jeszcze czy są kodujące (ang. possibly exonic UCEs). Sto z 256 niekodujących UCE zlokalizowane jest w intronach (sekwencjach niekodujących) znanych genów, a reszta znajduje się w regionach intergenicznych (stanowią ogromny procent genomu ludzkiego, mimo tego nadal są mało poznane, oddalone od poznanych dotąd grup genów kodujących białka, nie posiadające genów lub tylko kilka). Znane są również T-UCEs (ang. transcribed UCEs). Są

to fragmenty sekwencji zakwalifikowane jako non-exonic UCEs, jednak wykazujące dowody, że podlegają transkrypcji specyficznie dla tkanki, w której się znajdują i mogą wpływać na rozwój nowotworów u ludzi [8].

Sekwencje UCE są bardzo silnie konserwowane. W obrębie wszystkich UCEs (łącznie 106.767 nukleotydów) odkryto tylko 6 polimorfizmów pojedynczego nukleotydu (w skrócie SNP od ang. Single Nucleotide Polymorphism), co oznacza, że znaleziono jedynie 6 pojedynczych zmian nukleotydów w tych fragmentach DNA w ludzkiej populacji. SNP nie są mutacjami, ponieważ częstość ich występowanie przekracza 1%. Z powodu małej liczby SNP wysnuto wniosek, że UCEs posiadają ważne funkcje potrzebne do prawidłowego rozwoju badanych organizmów [9].

Przeprowadzone badania labolatoryjne na zarodkach transgenicznych myszy, z wszczepionymi ludzkimi UCE wykazały, że w regionach UCE znajdują się sekwencje regulatorowe. Obliczono, że 45% z wybranych sekwencji jest enhancerami regulującymi geny specyficzne dla tkanek oraz tworzy one moduły regulatorowe. Wykryto także sekwencje regulujące splicing oraz epigenetyczne modyfikacje.

1.5. Sekwencje ortologiczne oraz paralogiczne

Na podstawie sekwencji nukleotydowych lub aminokwasowych kodowanych białek można wnioskować o wspólnym pochodzeniu ewolucyjnym genów. Sekwencje posiadające wspólnego przodka nazywane są homologicznymi. Istnieją dwa rodzaje homologii - ortologia oraz paralogia. W analizie pokrewieństwa między organizmami rozróżnia się sekwencje, które pojawiły się w wyniku dublikacji w obrębie jednego gatunku (paralogi) oraz te, które są wynikiem rozdzielenia gatunków (ortologi) [17].

Często ustalenie, czy geny są ortologami, czy paralogami wymaga stwierdzenia, czy w danych warunkach duplikacja genu nastąpiła przed, czy po specjacji (procesie rozdzielenia gatunków).

Na rysunku 1.10 znajduje się przykład drzewa filogenetycznego, na którym widać, że jeden gen może mieć więcej niż jednego ortologa u drugiego gatunku (zarówno globiny alfa, jak i beta są ortologami w stosunku do globinowego genu minoga). Przykładem paralogów są geny globiny alfa i beta u żaby.

Ortologi zachowują te same funkcje oraz struktury biologiczne w danych organizmach. Zachowane ewolucyjnie są również najczęściej ich sekwencje nukleotydowe oraz role biologiczne. Z tego powodu są niezwykle pomocne przy identyfikacji genów w nowo zsekwencjonowanych genomach. W przeciwieństwie do ortologów, paralogi są mniej konserwowane ewolucyjnie [24].

Rysunek 1.10: Przykład drzewa filogenetycznego na podstawie sekwencji nukleotydowej globin w genomach minoga, żaby, kurczaka i myszy z obecnymi procesami dublikacji oraz specjacji [1].

Rozdział 2

Metody

Plan pracy

W celu znalezienia nadreprezentowanych motywów w zadanych sekwencjach w otoczeniu wybranych genów wykonano następujące kroki:

- znalezienie ortologów wybranej grupy genów,
- wybranie sekwencji w otoczeniu TSS genów w genomie referencyjnym oraz ich ortologów,
- znalezienie konserwowanych segmentów przyrównanych sekwencji,
- znalezienie w nich znanych lub/oraz wygenerowanie nowych motywów,
- statystyczna analiza motywów.

W tym rozdziale zostały opisane metody przeprowadzenia wyżej wypunktowanych procedur.

2.1. Baza danych sekwencji nukleotydowych Ensembl

Baza danych Ensembl pozwala na swobodny dostęp do informacji na temat genomów wielu kręgowców i innych gatunków eukariontycznych [18]. Umożliwia ona znalezienie zarówno ortologów jak i paralogów, a także wybranie dowolnych fragmentów sekwencji nukleinowych genomów w szczególności sekwencji oddalonych od TSS genów i ich ortologów o zadany przez użytkownika parametr.

2.2. Konserwowane segmenty MSA

Zachowane ewolucyjnie fragmenty DNA są interesujące pod względem występowania w nich potencjalnych sekwencji regulatorowych genów, jak opisano w rozdziale 1.4. W tym celu wybrane z bazy Ensembl sekwencje poddano najpierw multiuliniowieniu (ang. Multiple Sequence Alignment). Następnie wybrano z nich sekwencje należące bezpośrednio do postawowego promotora genu, ale także te znacznie oddalone od miejsca rozpoczęcia transkrypcji w obie strony nici DNA. Tak przygotowane sekwencje stanowiły dane wejściowe dla przedstawionego poniżej algorytmu 1. Wybiera on jak największe bloki konserwowanych segmentów MSA o dopuszczalnym procencie identyczności sekwencyjnej.

Algorytm 1

Require: $length[MSA] > 0$, $0.0 \leqslant ident \leqslant 1.0$, $block_length > 0$

1: $B \leftarrow _msa_to_binary_table(MSA)$
2: $stack \leftarrow [(0, length[B], length[B])]$
3: $blocks_ok \leftarrow []$
4: $T \leftarrow cumulative_sum(B)$
5: **while** $length[stack] > 0$ **do**
6: $\quad i, j, ln \leftarrow stack.pop()$
7: $\quad$ **while** $ln >= block_length$ **do**
8: $\quad\quad found \leftarrow False$
9: $\quad\quad$ **for** $k = i \rightarrow j - ln + 1$ **do**
10: $\quad\quad\quad$ **if** $fragment_ok(k, k + ln, ident, T) = True$ **then**
11: $\quad\quad\quad\quad blocks_ok.append((k, k + ln))$
12: $\quad\quad\quad\quad stack.append((i, k, ln - 1))$
13: $\quad\quad\quad\quad stack.append((k + ln, j, ln))$
14: $\quad\quad\quad\quad found \leftarrow True$
15: $\quad\quad\quad\quad break$
16: $\quad\quad\quad$ **end if**
17: $\quad\quad\quad$ **if** $found = True$ **then**
18: $\quad\quad\quad\quad break$
19: $\quad\quad\quad$ **else**
20: $\quad\quad\quad\quad ln \leftarrow ln - 1$
21: $\quad\quad\quad$ **end if**
22: $\quad\quad$ **end for**
23: $\quad$ **end while**
24: **end while**
25: **return** $blocks_ok$

W algorytmie funkcja pomocnicza `_msa_to_binary_table` oblicza tablicę binarną B taką, że:

$$B(i) = \begin{cases} 1 & \text{jeśli w kolumnie } i\text{-tej w każdym wierszu MSA występuje ten sam rodzaj nukloetydu} \\ 0 & \text{w przeciwnym przypadku} \end{cases}$$

Funkcja pomocnicza `cumulative_sum` tworzy tablicę sum częściowych T:

$$T(i) = \sum_{j=0}^{i-1} B(j)$$

Umożliwia ona sprawdzanie czy przetwarzany segment sekwencji posiada odpowiednią identyczność sekwencyjną (funkcja pomocnicza `fragment_ok` wywoływana w 10 linijce algorytmu) ze stałą złożonością czasową. Identyczność fragmentów uliniowienia od i-tego do j-tego nukleotydu wynosi:

$$\frac{T(j) - T(i)}{j - i}$$

Kolejka `stack` przetrzymuje trójelementowe krotki opisujące fragmenty MSA czekające na przetworzenie. Krotka (i, j, ln) oznacza, że we fragmencie od i-tego do j-tego nukleotydu MSA sprawdzane będą bloki długości $ln, ln - 1, \ldots, block_length$, gdzie parametr $block_length$

to zadana przez użytkownika minimalna dopuszczalna długość bloku. Jeśli dany fragment spełnia wymagania dodawany jest na listę `blocks_ok`. Algorytm wyszukuje odpowiednie segmenty sekwencji przeglądając je w kolejności od najdłuższych do najkrótszych.

Złożoność czasowa algorytmu w pesymistycznym przypadku wynosi O $(n * m + n^2)$, gdzie n to długość sekwencji w MSA, m to liczba sekwencji w MSA i przy założeniu, że sekwencje są nad ustalonym alfabetem {A,C,T,G}.

2.3. Statystyczna analiza motywów DNA

Można założyć, że motyw reprezentowany jest przez macierz PSSM. Fragment sekwencji może zostać uznany za instancję motywu, gdy jego ocena macierzy PSSM (wzór (1) w sekcji 1.3.1) jest większa niż zadany próg. Próg obliczany jest dla każdego motywu oddzielnie na podstawie wartości FPR (ang. False Positive Rate), czyli błędu typu I, zadanego przez użytkownika. FPR definiujemy jako:

$$FPR = \frac{FP}{FP + TN},$$

gdzie FP to liczba błędnie rozpoznanych pozycji instancji motywu w danej sekwencji, a TN to liczba poprawnie rozpoznanych miejsc, w których nie zaczyna się instancja motywu.

Przyjęto uproszczony model hipotezy zerowej, w której prawdopodobieństwo występowania motywu na ustalonej pozycji wynosi p dla każdej pozycji niezależnie (hipoteza zerowa mówi, że sekwencje są generowane z rozkładu tła, każda litera niezależnie). Wtedy prawdopodobieństwo zaobserwowania dokładnie k lub więcej instancji motywu w sekwencji o długości n wynosi:

$$P(K \geqslant k) = \sum_{i=k}^{n} P(K = i) = \sum_{i=k}^{n} \binom{n}{i} p^i (1-p)^{n-i},$$

gdzie K to liczba sukcesów w schemacie Bernoulliego z n próbami i prawdopodobieństwem sukcesu p.

Przyjęto, że hipoteza zerowa jest odrzucana, gdy to prawdopobieństwo (tzw. p-wartość) jest dostatecznie niskie . Wtedy motyw uznawany jest za nadreprezentowany.

W celu weryfikacji hipotez posłużono się testem dwumianowym z poprawką Bonferroniego. Hipoteza zerowa jest więc odrzucana, gdy jej p-wartość jest mniejsza niż $\frac{\alpha}{m}$:

$$P(K \geqslant k) < \frac{\alpha}{m},$$

gdzie m to liczba wszystkich znalezionych motywów, a α to prawdopodobieństwo fałszywego odrzucenia co najmniej jednej hipotezy zerowej.

2.4. Opis implementacji

W celu wykonania procedur opisanych w sekcjach 2.1-2.3 zaimplementowano trzy moduły w języku Python korzystające z biblioteki Biopython [28]: Ensembl, CNS oraz STATS.

Ensembl

Baza danych ENSEMBL jest bazą danych zawierający m.in sekwencje genomaów kręgowców i innych gatunków eukariontycznych i umożliwia swobodny do nich dostęp przez internet [18]. W pracy wykorzystano dostęp do jej publicznego serwera MySQL [5].

Moduł Ensembl zawiera dwie klasy: Compara i Genome, które korzystają z dwóch dostępnych baz: Comparative Genomics oraz Core (stanowią część bazy Ensembl) [3]. W bazie Comparative Genomics przetrzymywane są informacje o homologach (paralogach i ortologach) genów oraz rodzinach białek. Natomiast Core zawiera tabele opisujące zsekwencjonowane genomy kilkudziesięciu kręgowców i adnotacje do sekwencji posiadających znane role biologiczne.

Konstruktor klasy Compara wymaga parametru `release`, który informuje o wersji bazy. Obiekt tej klasy posiada metodę `get_related_genes` pozwalającą na wyszukanie homologów danego genu. Przyjmuje ona następujące parametry:

- `species` = lista gatunków, w których szukane są homologi
- `ref_gene_id` = identyfikator genu na nici referencyjnej dostępny w bazie ENSEMBL [2]
- `relationship` = zależność pomiędzy genem referencyjnym, a poszukiwanymi genami w liscie gatunków `species`

Przykładowe drzewo z możliwymi relacjami między genami przedstawione jest na rysunku 2.1.

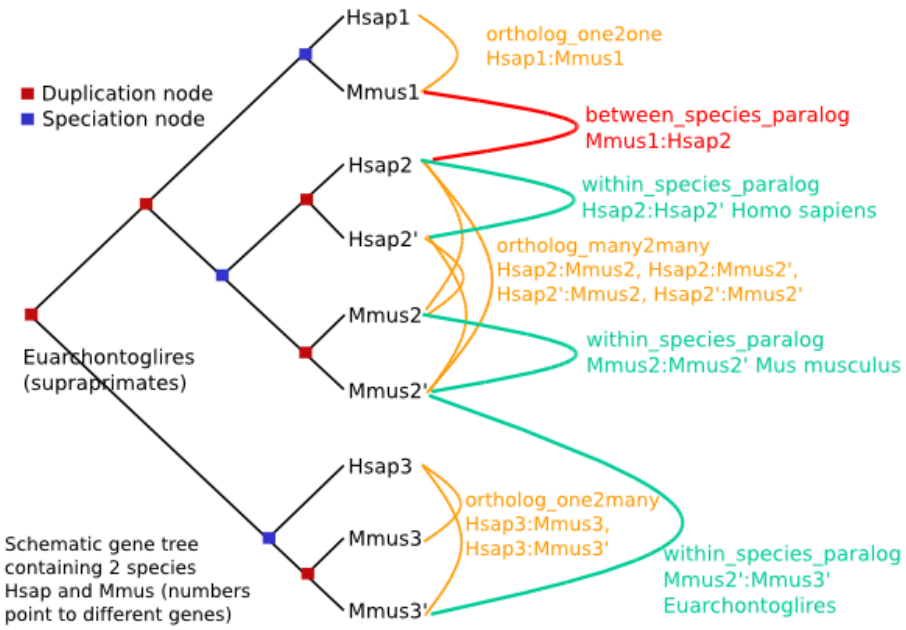

Rysunek 2.1: Drzewo filogenetyczne genów należących do gatunków Hsap oraz Mmus z grupy *Euarchontoglires*. Zaznaczono przykładowe możliwe relacje między nimi dostępne w bazie Comparative Genomics. Czerwony węzeł przedstawia proces duplikacji genu, niebieski specjację [4].

Informacje o wszystkich możliwych związkach pomiędzy genami oraz o dostępnych gatunkach dostarczają metody `available_relationships` oraz `available_spieces`.

Konstruktor klasy Genome przyjmuje parametry `release` (analogicznie jak w klasie Compara) oraz `genome_name` wskazujący nazwę genomu. Klasa posiada metody pozwalające na uzyskanie informacji o fragmentach sekwencji genomu, ich współrzędnych określających miejsce w genomie oraz/lub adnotacji biologicznych. Wszystkie zwracają obiekty klasy Bio.SeqRecord z biblioteki Biopython, a metoda `get_gene_by_description` listę z tymi obiektami. Metody mają następujące sygnatury:

- `get_gene_by_stable_id`:
  - `stable_id` = identyfikator genu w bazie ENSEMBL
- `get_gene_by_name` :
  - `name` = nazwa genu w bazie ENSEMBL
- `get_region`:
  - `coord_name` = nazwa chromosomu
  - `coord_start` = liczba określająca początek poszukiwanego regionu
  - `coord_end` = liczba określająca koniec poszukiwanego regionu
  - `coord_strand` = orientacja na nici DNA, przyjmuje wartości 1 dla nici sensownej (5'-3') i -1 dla antysensownej (3'-5').
- `get_genes_by_description`:
  - `description` = opis genu dostępny w ENSEMBL

Metoda `get_genes_by_description` szuka danego wzorca w opisach wszystkich znanych genów. Jest on wyszukiwany poprzez zapytania MySQL. Możliwe jest więc użycie znaków specjalnych, jak na przykład '%','_'. Więcej informacji dostępnych jest w dokumentacji MySQL [27].

CNS

Moduł CNS (ang. Conserved Noncoding Sequences) został zaimplementowany w celu wyszukiwania zachowanych ewolucyjnie segmentów w przyrównanych sekwencjach.

Jedynym parametrem konstruktora klasy CNS jest multiuliniowienie jako obiekt klasy Bio.AlignIO. Uzyskanie konserwowanych segmentów MSA umożliwia metoda `get_conserved_blocks_of_MSA` zgodnie z algorytmem opisanym w sekcji 2.2. Przyjmuje ona argumenty:

- `block_length` = minimalna długość segmentu multiuliniowienia
- `ident` = minimalny procent identyczności segmentu.

STATS

W module STATS zaimplementowano funkcje umożliwiające statystyczną analizę motywów.

Kontruktor klasy przyjmuje parametry:

- `MSAs` = lista MSA w postaci obiektów klasy Bio.AlignIO

Dostępna jest motoda `number_of_occurrences` obliczająca liczbę wystąpień motywu w liście multiuliniowień, wymagająca parametrów:

- `motif` = motyw w postaci obiektu klasy Bio.Motif
- `fpr` = błąd I typu, false positive rate (opisany w sekcji 2.3)

Metoda `overrepresented_motifs` zwraca listę motywów nadreprezentowanych obliczanych na podstawie opisu w sekcji 2.3. Korzysta z funkcji `number_of_occurrences`, dlatego oprócz parametrów `motif` oraz `fpr`, przyjmuje również:

- `alpha` = poziom istotności dla pojedynczej hipotezy zerowej (opisany w sekcji 2.3)
- `p` = prawdopodobieństwo zaobserwowania motywu na ustalonej pozycji sekwencji z rozkładu tła.

Rozdział 3

Przykład zastosowania

Ten rozdział przedstawia przykładowe użycie modułów Ensembl, CNS oraz STATS dla genów kodujących miozynę. Miozyny to rodzina białek motorycznych zależnych od ATP, których główną rolą jest udział w skurczach mięśni oraz innych licznych procesach związanych z ruchem u organizmów eukariontycznych. Ich struktura i funkcja jest silnie konserwowana. Praktycznie wyszystkie eukarionty posiadają ich geny [29].

W pierwszym kroku znaleziono potencjalne sekwencje regulatorowe związane z genami kodującymi białka z rodziny miozyn w genomach *Homo Sapiens*, *Rattus norvegicus* i *Mus musculus*. W tym celu użyto modułu Ensembl, aby znaleźć najpierw ortologi genów ludzkich w genomach szczura oraz myszy, a następnie wyodrębnić 10 tysięcy par zasad w stronę 5' oraz 3' nici DNA od miejsc rozpoczęcia tranksrypcji wybranych genów.

Używając metody

```
get_genes_by_description("myosin%")
```

obiektu klasy Genome odnaleziono 80 genów kodujących białka związane z miozyną w genomie człowieka. Następnie wybrano ich ortologii w genomach myszy i szczura metodą obiektu klasy Compara:

```
get_related_genes(species=['Rattus Norvegicus','Mus musculus'],
    ref_gene_id=gene.id,relationship="ortholog_one2one").
```

Nie wszystkie wybrane w ten sposób geny posiadają swoje ortologi w relacji `ortholog_one2one` jednocześnie w genomach myszy oraz szczura, dlatego ich liczba z początkowej zmniejszyła się do 47. Wyodrębnione sekwencje regulatorowe poddano uliniowieniu programem MUSCLE [16]. Używając modułu CNS znaleziono w nich konserwowane bloki sekwencji przy minimalnej długości segmentu multiuliniowienia 100 nukleotydów oraz 70% identyczności sekwencji. W tym celu użyto metody

```
get_conserved_blocks_of_MSA(block_length=100,ident=0.70).
```

Znaleziono 49 segmentów MSA należących do otoczenia genów MYH7B, MYL1, MYLK2, MYLPF, MYO1D oraz MYL9. Rysunek 3.1 przedstawia liczbę znalezionych segmentów w otoczeniu tych genów.

Rysunek 3.2 przedstawia ilość znalezionych bloków. Procent identyczności sekwencyjnej segmentów nie przekracza 70.6%. Długość segmentów wynosi od 100 do 2997 nukleotydów. Większość segmentów posiada do 500 nukleotydów.

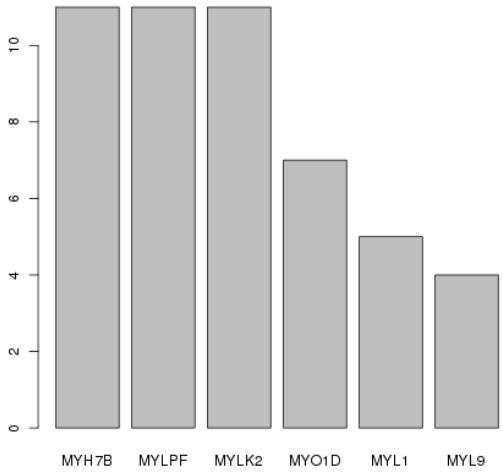

Rysunek 3.1: Nazwy ludzkich, mysich oraz szczurzych genów (posiadają taką samą nazwę), w których otoczeniu znaleziono odpowiednio zamieszczone w tabeli liczby segmentów większych niż 100 nukleotydów i posiadające identyczność nie mniejszą 70%.

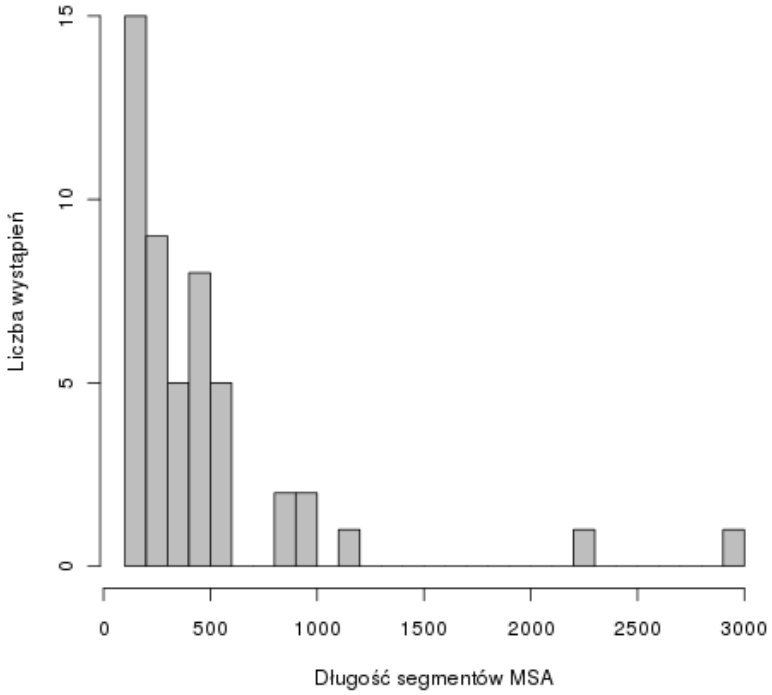

Rysunek 3.2: Ilość znalezionych segmentów MSA.

W obliczeniach wykorzystano motywy należące do kręgowców znajdujące się w bazie JASPAR CORE [31]. Zawiera ona 138 motywów reprezentowanych przez macierze opisujących

częstość występowania nukleotydów na odpowiednich pozycjach motywu. W obliczeniach wykorzystane zostały te motywy, które występują w genomach człowieka, myszy oraz szczura. Ich nazwy widoczne są w tabeli 3.1.

Tabela 3.1: Tabela przedstawia motywy z bazy JASPAR CORE należące do genomów człowieka, myszy i szczura.

MA0002.2	MA0003.1	MA0004.1	MA0006.1	MA0007.1	MA0163.1	MA0442.1	MA0150.1
MA0009.1	MA0014.1	MA0017.1	MA0018.2	MA0019.1	MA0024.1	MA0259.1	MA0149.1
MA0025.1	MA0027.1	MA0028.1	MA0029.1	MA0030.1	MA0031.1	MA0258.1	MA0148.1
MA0032.1	MA0033.1	MA0035.2	MA0036.1	MA0037.1	MA0038.1	MA0164.1	MA0147.1
MA0039.2	MA0040.1	MA0041.1	MA0042.1	MA0043.1	MA0046.1	MA0162.1	MA0146.1
MA0047.2	MA0048.1	MA0050.1	MA0051.1	MA0052.1	MA0055.1	MA0161.1	MA0144.1
MA0056.1	MA0057.1	MA0058.1	MA0059.1	MA0060.1	MA0061.1	MA0160.1	MA0143.1
MA0062.2	MA0063.1	MA0065.2	MA0066.1	MA0067.1	MA0068.1	MA0159.1	MA0142.1
MA0069.1	MA0070.1	MA0071.1	MA0072.1	MA0073.1	MA0074.1	MA0158.1	MA0141.1
MA0075.1	MA0076.1	MA0077.1	MA0078.1	MA0079.2	MA0080.2	MA0157.1	MA0140.1
MA0081.1	MA0083.1	MA0084.1	MA0087.1	MA0088.1	MA0089.1	MA0156.1	MA0145.1
MA0090.1	MA0091.1	MA0092.1	MA0093.1	MA0095.1	MA0098.1	MA0155.1	MA0139.1
MA0099.2	MA0100.1	MA0101.1	MA0102.2	MA0103.1	MA0104.2	MA0154.1	MA0138.2
MA0105.1	MA0106.1	MA0107.1	MA0108.2	MA0109.1	MA0111.1	MA0153.1	MA0137.2
MA0112.2	MA0113.1	MA0114.1	MA0115.1	MA0116.1	MA0117.1	MA0152.1	MA0136.1
MA0119.1	MA0122.1	MA0124.1	MA0125.1	MA0130.1	MA0131.1	MA0151.1	MA0135.1
MA0132.1	MA0133.1						

Motywy wygenerowano również de novo, za pomocą programów MEME oraz AlignACE. W ten sposób uzyskano 40 nowych motywów.

Nadreprezentowanych motywów szukano za pomocą metody klasy Stats z uwzględnieniem poprawki Bonferroniego (dla poziomu istotności równego 0.05 i liczbą wszystkich motywów 178) z parametrami:

```
stats.overrepresented_motifs(p=0.1,alpha=0.00028,fpr=0.1).
```

Znaleziono łącznie 91 nadreprezentowanych motywów: 1 wygenerowany programem MEME, 39 wygenerowanych programem AlignACE oraz 51 pochodzących z bazy JASPAR. Ich graficzne logo są zamieszczone w Dodatku A.

Rozdział 4

Podsumowanie

W pracy przedstawiono metodologię wyszukiwania nadreprezentowanych motywów w regionach genów oraz ich ortologów. Została ona zaimplementowana w języku Pythona z użyciem biblioteki Biopython. Testowano je na rodzinie genów kodujących białka z rodziny miozyn u człowieka, myszy oraz szczura. Zidentyfikowano 91 nadreprezentowanych motywów pochodzących z bazy JASPAR oraz wygenerowanych programami MEME oraz AlignACE.

Dodatek A

Nadreprezentowane motywy

Rysunek A.1: Nadreprezentowany motyw wygenerowany przez program MEME.

Rysunek A.2: Nadreprezentowane motywy wygenerowane programem AlignACE według rosnącej p-wartości [23].

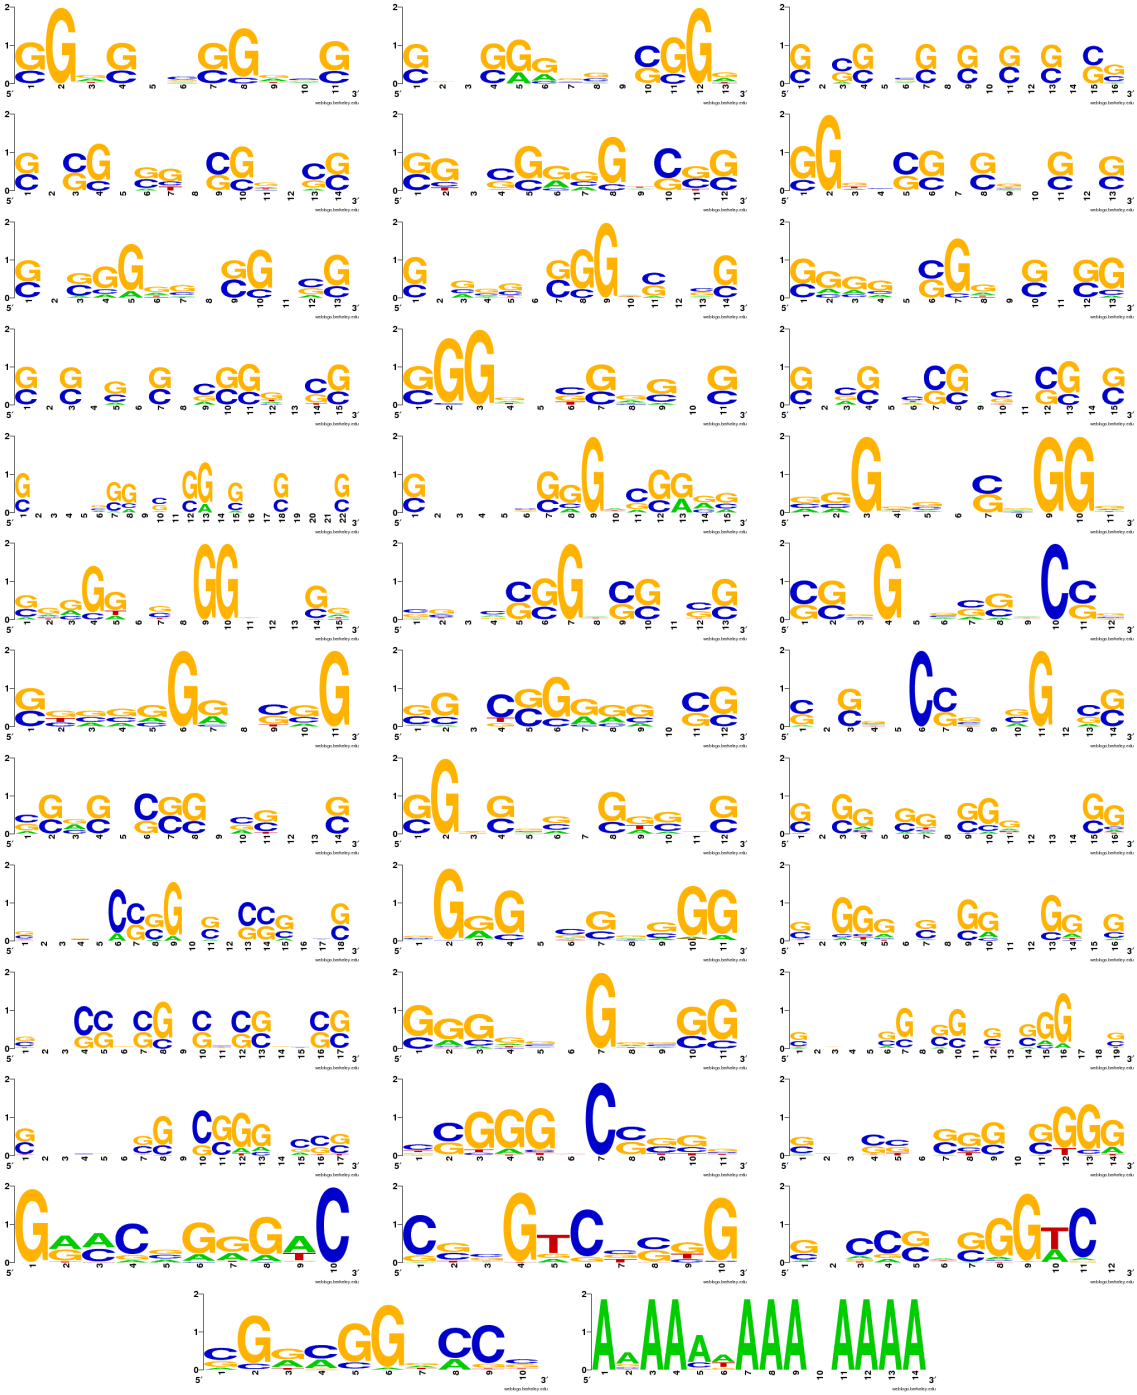

Rysunek A.3: Nadreprezentowane motywy z bazy JASPAR CORE według rosnącej p-wartości.

Rysunek A.4: MA0036.1

Rysunek A.5: MA0039.2

Rysunek A.6: MA0056.1

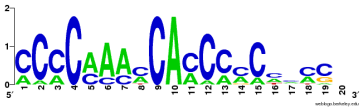
Rysunek A.7: MA0073.1

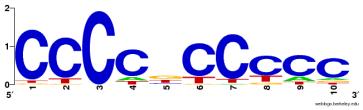
Rysunek A.8: MA0079.2

Rysunek A.9: MA0080.2

Rysunek A.10: MA0098.1

Rysunek A.11: MA0103.1

Rysunek A.12: MA0115.1

Rysunek A.13: MA0149.1

Rysunek A.14: MA0163.1

Rysunek A.15: MA0105.1

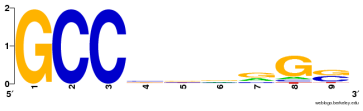
Rysunek A.16: MA0003.1

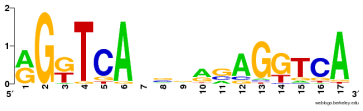
Rysunek A.17: MA0159.1

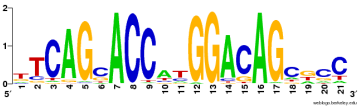
Rysunek A.18: MA0138.2

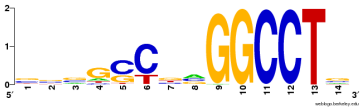
Rysunek A.19: MA0146.1

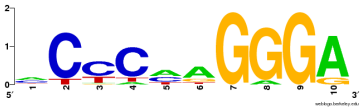
Rysunek A.20: MA0154.1

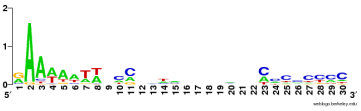
Rysunek A.21: MA0068.1

Rysunek A.22: MA0074.1

Rysunek A.23: MA0162.1

Rysunek A.24: MA0057.1

Rysunek A.25: MA0116.1

Rysunek A.26: MA0061.1

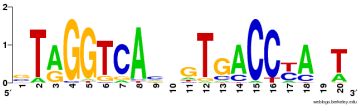
Rysunek A.27: MA0066.1

Rysunek A.28: MA0113.1

Rysunek A.29: MA0155.1

Rysunek A.30: MA0014.1

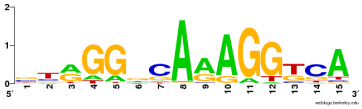

Rysunek A.31: MA0065.2

Rysunek A.32: MA0089.1

Rysunek A.33: MA0062.2

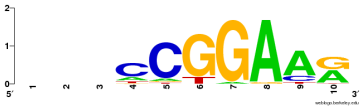

Rysunek A.34: MA0028.1

Rysunek A.35: MA0076.1

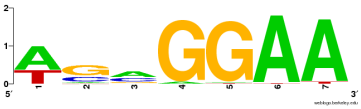

Rysunek A.36: MA0081.1

Rysunek A.37: MA0124.1

Rysunek A.38: MA0442.1

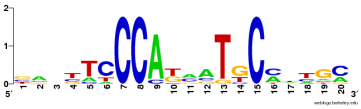

Rysunek A.39: MA0088.1

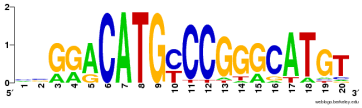

Rysunek A.40: MA0106.1

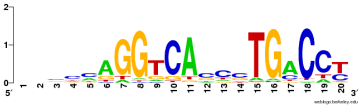

Rysunek A.41: MA0112.2

Rysunek A.42: MA0041.1

Rysunek A.43: MA0009.1

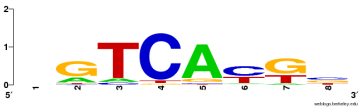

Rysunek A.44: MA0067.1

Rysunek A.45: MA0051.1

Rysunek A.46: MA0090.1

Rysunek A.47: MA0111.1

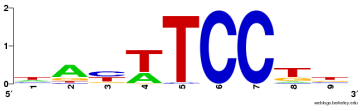

Rysunek A.48: MA0136.1

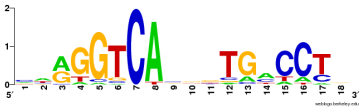

Rysunek A.49: MA0258.1

Rysunek A.50: MA0143.1

Rysunek A.51: MA0141.1

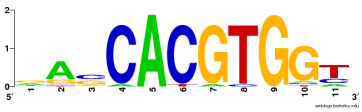

Rysunek A.52: MA0059.1

Rysunek A.53: MA0109.1

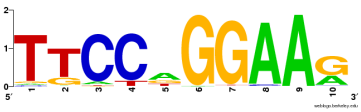

Rysunek A.54: MA0144.1

Rysunek A.55: MA0027.1

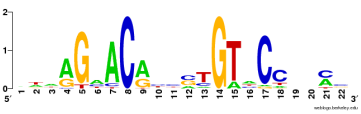

Rysunek A.56: MA0007.1

Bibliografia

[1] URL http://www.deltami.edu.pl/temat/roznosci/biologia/2011/02/10/Skad_sie_biora_geny_.

[2] . URL http://www.ensembl.org/index.html.

[3] . URL http://www.ensembl.org/info/docs/api/index.html.

[4] . URL http://www.ensembl.org/info/docs/compara/homology_method.html.

[5] . URL http://www.ensembl.org/info/data/mysql.html.

[6] URL http://www.genetyka.citiesxl.com.pl/struktura dna 2.

[7] Timothy L. Bailey, Nadya Williams, Chris Misleh, and Wilfred W. Li. *Nucleic Acids Research*, 34(Web-Server-Issue):369–373, 2006.

[8] E. Baira, J. Greshock, G. Coukos, and L. Zhang. Ultraconserved elements: genomics, function and disease. *RNA Biol*, 5(3):132–134, 2008.

[9] G. Bejerano, M. Pheasant, I. Makunin, S. Stephen, W. J. Kent, J. S. Mattick, and D. Haussler. Ultraconserved elements in the human genome. *Science*, 304(5675):1321–1325, May 2004.

[10] Terry A. Brown. *Genomy*, pages 305–327. Wydawnictwo Naukowe PWN, 2009.

[11] J. E. Butler and J. T. Kadonaga. The RNA polymerase II core promoter: a key component in the regulation of gene expression. *Genes Dev.*, 16(20):2583–2592, Oct 2002.

[12] David P. Clark. *Molecular Biology*, pages 263–270. Elsevier Academic Press, 2005.

[13] F. Crick. Central dogma of molecular biology. *Nature*, 227(5258):561–563, Aug 1970.

[14] P. D'haeseleer. How does DNA sequence motif discovery work? *Nat. Biotechnol.*, 24(8): 959–961, Aug 2006.

[15] Patrik D'haeseleer. What are DNA sequence motifs? *Nature Biotechnology*, 24:423–425, 2006.

[16] R. C. Edgar. MUSCLE: multiple sequence alignment with high accuracy and high throughput. *Nucleic Acids Res.*, 32(5):1792–1797, 2004.

[17] W. M. Fitch. Distinguishing homologous from analogous proteins. *Syst. Zool.*, 19:99–113, 1970.

[18] T. Hubbard, D. Barker, E. Birney, G. Cameron, Y. Chen, L. Clark, T. Cox, J. Cuff, V. Curwen, T. Down, R. Durbin, E. Eyras, J. Gilbert, M. Hammond, L. Huminiecki, A. Kasprzyk, H. Lehvaslaiho, P. Lijnzaad, C. Melsopp, E. Mongin, R. Pettett, M. Pocock, S. Potter, A. Rust, E. Schmidt, S. Searle, G. Slater, J. Smith, W. Spooner, A. Stabenau, J. Stalker, E. Stupka, A. Ureta-Vidal, I. Vastrik, and M. Clamp. The Ensembl genome database project. *Nucleic Acids Research*, 30(1):38–40, 2002.

[19] David S. Latchman. Transcription factors: An overview. *The International Journal of Biochemistry & Cell Biology*, 29(12):1305–1312, December 1997.

[20] Department of Biology at Kenyon College. URL `http://biology.kenyon.edu/courses/biol114/Chap10/Chap10.html`.

[21] Harvard University Office of Technology Development. URL `http://atlas.med.harvard.edu/cgi-bin/alignace.pl`.

[22] Nomenclature Committee of the International Union of Biochemistry (NC-IUB). Nomenclature for incompletely specified bases in nucleic acid sequences, 1984. URL `http://www.chem.qmul.ac.uk/iubmb/misc/naseq.html`.

[23] F.R. Roth, J. D. Hughes, and P. E. G.M. Church Estep. Finding DNA Regulatory Motifs within Unaligned Non-Coding Sequences Clustered by Whole-Genome mRNA Quantitation. *Nature Biotechnology*, 1998.

[24] D. B. Searls. Pharmacophylogenomics: genes, evolution and drug targets. *Nat Rev Drug Discov*, 2(8):613–623, Aug 2003.

[25] S. T. Smale and J. T. Kadonaga. The RNA polymerase II core promoter. *Annu. Rev. Biochem.*, 72:449–479, 2003.

[26] Maria Stepanova, Tatiana Tiazhelova, Mikle Skoblov, and Ancha Baranova. A comparative analysis of relative occurrence of transcription factor binding sites in vertebrate genomes and gene promoter areas. *Bioinformatics*, 21(9):1789–1796, May 2005. ISSN 1367-4803.

[27] The Documentation of MySQL Server. URL `http://dev.mysql.com/doc/`.

[28] The official website Biopython. URL `http://biopython.org/`.

[29] R. F. Thompson and G. M. Langford. Myosin superfamily evolutionary history. *Anat. Rec.*, 268(3):276–289, Nov 2002.

[30] A. Visel, S. Prabhakar, J. A. Akiyama, M. Shoukry, K. D. Lewis, A. Holt, I. Plajzer-Frick, V. Afzal, E. M. Rubin, and L. A. Pennacchio. Ultraconservation identifies a small subset of extremely constrained developmental enhancers. *Nat. Genet.*, 40(2):158–160, Feb 2008.

[31] D. Vlieghe, A. Sandelin, P. J. De Bleser, K. Vleminckx, W. W. Wasserman, F. van Roy, and B. Lenhard. A new generation of JASPAR, the open-access repository for transcription factor binding site profiles. *Nucleic Acids Res.*, 34(Database issue):D95–97, Jan 2006.

[32] Jin Xiong. *Podstawy Bioinformatyki*, pages 100–103. Wydawnictwo Uniwersytetu Warszawskiego, 2006.

[33] Jin Xiong. *Podstawy Bioinformatyki*, pages 81–83. Wydawnictwo Uniwersytetu Warszawskiego, 2006.